

直接激光惯性里程计： 具有连续时间运动校正的轻量级激光惯性里程计

Kenny Chen¹, Ryan Nemiroff¹, and Brett T. Lopez²

Abstract—敏捷飞行或穿越不规则地形的激进运动会导致激光雷达扫描中的运动失真，从而降低状态估计和映射。有一些方法来减轻这种影响，但对于资源受限的移动机器人来说，它们仍然过于简单或计算成本过高。为此，本文提出了直接激光雷达惯性里程计 (DLIO)，这是一种轻量级的激光雷达惯性里程测量算法，采用了一种新的从粗到细的方法来构建连续时间轨迹，以进行精确的运动校正。我们方法的关键在于构建一组仅由时间参数化的分析方程，从而实现快速且可并行的逐点去畸变。该方法之所以可行，是因为我们的非线性几何观测器具有很强的收敛特性，为初始化敏感的 IMU 积分步骤提供了可证明正确的状态估计。此外，通过同时执行运动校正和先验积分，并将每次扫描直接配准到地图上而不是帧到帧配准，DLIO 的压缩架构的计算效率比当前最先进的架构高出近 20%，精度提高了 12%。通过使用多个公共基准和自行收集的数据集进行广泛测试，我们证明了与四种最先进的算法相比，DLIO 具有更高的定位精度、地图质量和更低的计算开销。

I. INTRODUCTION

精确的实时状态估计和建图是移动机器人感知、规划和在未知环境中导航的必要能力。由于现在的传感器更小巧、更精确，基于激光雷达的定位最近已成为许多移动平台（如无人机）的可行选择。因此，研究人员开发了几种新的 LiDAR 里程计 (LO) 和 LiDAR 惯性里程计 (LIO) 算法，由于 LiDAR 具有卓越的距离和深度测量精度，这些算法通常优于基于视觉的方法。然而，在开发可靠和准确的以激光雷达为中心的算法 [1] 方面仍然存在根本性的挑战，特别是对于执行敏捷机动或穿越不平坦地形的机器人。特别是，这种激进的运动会在点云中引起显著的失真，从而破坏扫描匹配过程，导致严重或灾难性的定位误差和地图变形。

¹Kenny Chen and Ryan Nemiroff are with the Department of Electrical and Computer Engineering, University of California Los Angeles, Los Angeles, CA, USA. {kennyjchen, ryguyn}@ucla.edu

²Brett T. Lopez is with the Department of Mechanical and Aerospace Engineering, University of California Los Angeles, Los Angeles, CA, USA. btlopez@ucla.edu

All authors are with the Verifiable and Control-Theoretic Robotics Laboratory, University of California Los Angeles, Los Angeles, CA, USA.

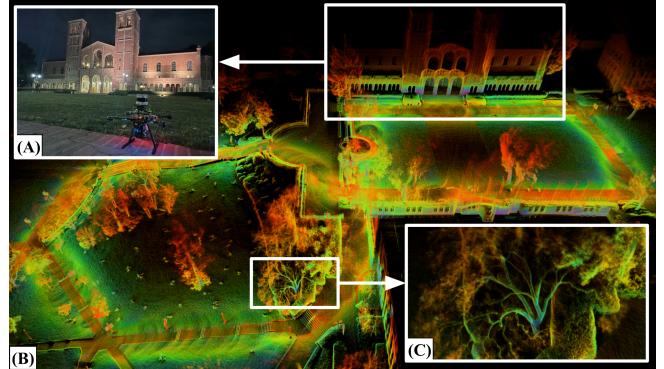


Fig. 1. 实时定位与稠密建图。DLIO 通过实时可靠地估算机器人姿态、速度和传感器偏差来生成详细地图。(A) 我们的定制飞行器在加州大学洛杉矶分校罗伊斯大厅 (Royce Hall) 旁。(B) DLIO 生成的罗伊斯大厅及其周边环境的鸟瞰图。(C) 一棵树的特写，展示了 DLIO 在其输出地图中能够捕捉到的精细细节。颜色表示点返回的强度。

现有的一些算法试图补偿这种影响，它们在非完整系统（例如自动驾驶）的结构化环境中可能效果良好，但由于运动模型过于简单、离散化导致精度损失或计算效率低下，在非规则条件下的性能可能会下降。例如，[2]–[4] 等算法假设扫描采集过程中的速度恒定，这对于简单、可预测的轨迹可能效果良好，但在显著加速的情况下很快就会失效。另一方面，[5] 和 [6] 使用反向传播技术来减轻每个点的失真，但它们的方法可能会因积分误差随时间累积而导致精度损失。最近，连续时间方法尝试在一组控制点上拟合平滑轨迹 [24], [25] 或使用额外的自由变量增强扫描匹配优化 [27]，但此类方法仍然对轨迹（即平滑运动）有一个强假设条件，或者对于重量有限的平台来说计算成本太高。

为此，我们提出了直接激光雷达-惯性里程计 (DLIO)，这是一种快速可靠的里程计算法，可提供精确的定位和详细的 3D 建图 (Fig. 1)，其主要贡献如下：首先，我们提出了一种新的由粗到精的连续时间轨迹构建技术，推导了一组具有恒定加速度和角加速度运动模型的解析方程，以实现快速且可并行的逐点运动校正；其次，我们提出了一种新颖的精简架构，将运动校正和 IMU 预测结合为一步，并直接执行扫描到地图的配准，从而显著降低了算法的总体计算

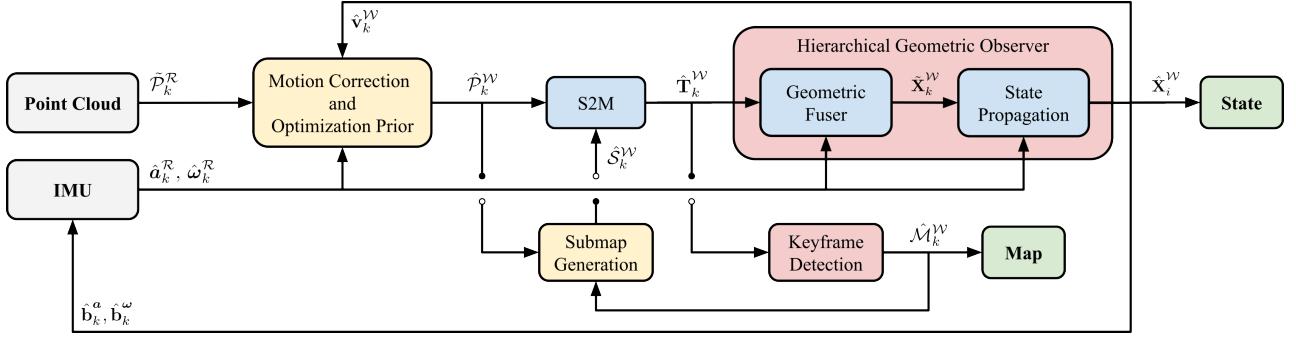


Fig. 2. 系统架构。DLIO 的轻量级架构将运动校正和 IMU 预测合并为一个步骤，并且移除了之前基于 LiDAR 的里程计所需的扫描到扫描模块。 W 中的逐点连续时间积分可确保校正点云的最大保真度，并通过基于 GICP 的自定义扫描匹配器将其注册到机器人地图上。随后，系统状态由具有强收敛特性 [7] 的非线性几何观测器更新，这些位姿、速度和偏差的估计值随后初始化下一次迭代。

开销；第三，我们利用一种新的非线性几何观测器 [7]，它具有强大的性能保证——这对于实现前两个贡献至关重要——以最小的计算复杂度稳健地生成机器人完整状态的精确估计。

最后，我们的方法的有效性通过使用多个数据集与最新技术进行广泛的实验结果得到了验证。

II. RELATED WORK

几何激光雷达里程计算法依赖于通过求解非线性最小二乘问题来对齐点云，该问题最小化对应点和平面之间的误差。为了找到点/平面的对应关系，诸如迭代最近点 (ICP) 算法 [8], [9] 或广义 ICP (GICP) [10] 之类的方法会递归地匹配实体，直到对齐收敛到局部最小值。

在确定大量点的对应关系时，通常会观察到收敛时间较慢的问题，因此基于 特征的方法 [2]–[5], [11]–[14] 会尝试在扫描中仅提取最显著的数据点（例如角和边），以减少计算时间。然而，由于特征提取的有效性高度依赖于具体的实现，有用的点通常会被丢弃。相反，稠密方法 [6], [15]–[18] 直接对齐获取的扫描，但通常严重依赖于积极的体素化（一种可以改变重要数据对应的过程）以实现实时性能。

激光雷达里程计方法也可以根据其将其他传感方式纳入估计管道的方法进行分类。

松耦合方法 [2], [3], [15]–[17] 顺序处理传感器数据。例如，IMU 测量用于通过提供优化先验来增强 LiDAR 扫描配准。由于激光雷达测量的精度，这些方法通常非常稳健，但由于仅使用所有可用数据的一个子集进行估计，定位结果可能不太准确。

紧耦合方法 [4], [6], [13], [14]，另一方面，通过联合考虑所有传感方式的测量值，可以提高精度。

这些方法通常采用基于图的优化 [4], [13], [14], [19] 或随机滤波框架，例如卡尔曼滤波器 [5], [6]。然而，与几何观测器 [20], [21] 相比，即使在最理想的设置下，这些方法也仅能提供极低的收敛保证，这可能导致传感器融合不一致导致的显著定位误差，以及扫描位置不正确导致的地图变形。

结合额外的传感器也有助于校正运动引起的点云失真。例如，LOAM [2] 通过扫描匹配和使用恒速假设的松耦合 IMU 迭代估计传感器姿态来补偿自旋失真。同样，LIO-SAM [4] 在因子图上制定了 LiDAR 惯性里程计，以共同优化物体速度，在实施过程中，通过线性插值旋转运动来消除点的偏移。FAST-LIO [5] 和 FAST-LIO2 [6] 在 IMU 测量的正向传播后，对点时间戳采用反向传播步长，以产生对扫描结束时间的相对变换。然而，这些方法（以及其他方法 [22], [23]）都是在离散时间中处理，这可能会导致精度损失，从而引起人们对连续时间方法。例如，Elastic LiDAR Fusion [24] 通过优化连续线性轨迹来处理扫描变形，而 Wildcat [25] 和 [26] 则迭代地拟合三次 B 样条，以消除曲面图中的失真。最近，CT-ICP [27] 和 ElasticLiDAR++ [28] 使用仅激光雷达的方法来定义由每次扫描两个姿态参数化的连续时间轨迹，这允许在优化过程中对扫描进行弹性配准。然而，这些方法在模拟高度动态运动下的轨迹时仍然过于简单，或者计算成本太高，无法实时可靠地工作。

为此，DLIO 提出了一种快速、从粗到细的方法来构建每个激光雷达扫描之间的轨迹，以进行精确的运动校正。首先通过 IMU 测量的数值积分计算一组离散的姿态，随后通过分析的连续时间方程建立测量样本之间的平滑轨迹，以查询每个点的位姿变换矩阵。我们的方法很快，因为我们解决的是一组分析方程，而

不是一个优化问题（例如样条拟合），仅由点的时间戳参数化，可以很容易地并行化。我们的方法也是准确的，因为我们使用高阶运动模型来表示底层系统动力学，该模型可以捕捉高频运动，否则这些高频运动可能会在试图将平滑轨迹拟合到一组控制点的方法中丢失。该方法内置于简化的 LIO 架构中，该架构在一次扫描中执行运动校正和 GICP 先验构建，此外还直接执行扫描到映射对齐，而无需中间帧到帧配准；这一切都可以通过我们的新型几何观测器的强收敛保证来实现，该观测器具有可证明正确的状态估计。

III. METHOD

A. System Overview

DLIO 是一种轻量级的 LIO 算法，它通过独特的架构生成机器人状态估计和几何地图，该架构包含两个主要组件，并包含三项创新 (Fig. 2)。第一个组件是快速扫描匹配器，它通过与提取的局部子图进行对齐，将密集的、经过运动校正的点云配准到机器人地图上。 \mathcal{W} 中的逐点连续时间积分确保了校正点云的最大图像保真度，同时为 GICP 优化构建了先验。在第二个组件中，非线性几何观测器 [7] 使用第一个组件的位姿输出更新系统状态，从而提供高速且可证明正确的位姿、速度和传感器偏差估计，这些估计能够全局收敛。然后，这些估计将初始化下一轮运动校正、扫描匹配和状态更新的迭代。

B. Notation

设由单一激光雷达在时间 t_k 处扫描得到的点云为 \mathcal{P}_k ，并以 k 为索引。点云 \mathcal{P}_k 由点 $p_k^n \in \mathbb{R}^3$ 组成，这些点是在相对于扫描开始的时间 Δt_k^n 测量的，并由 $n = 1, \dots, N$ 进行索引，其中 N 是扫描中点的总数。世界坐标系记为 \mathcal{W} ，机器人坐标系记为 \mathcal{R} ，位于其重心处，约定 x 轴指向前方， y 轴指向左侧， z 轴指向上方。IMU 的坐标系记为 \mathcal{B} ，LiDAR 的坐标系记为 \mathcal{L} ，索引为 k 的机器人状态向量 \mathbf{X}_k 定义为

$$\mathbf{X}_k = [\mathbf{p}_k^\mathcal{W}, \mathbf{q}_k^\mathcal{W}, \mathbf{v}_k^\mathcal{W}, \mathbf{b}_k^\mathcal{a}, \mathbf{b}_k^\mathcal{\omega}]^\top, \quad (1)$$

其中 $\mathbf{p}^\mathcal{W} \in \mathbb{R}^3$ 是机器人的位置， $\mathbf{q}^\mathcal{W}$ 是在哈密顿符号下由 \mathbb{S}^3 上的四向量四元数编码的方向， $\mathbf{v}^\mathcal{W} \in \mathbb{R}^3$ 是机器人的速度， $\mathbf{b}^\mathcal{a} \in \mathbb{R}^3$ 是加速度计的偏差， $\mathbf{b}^\mathcal{\omega} \in \mathbb{R}^3$ 是陀螺仪的偏差。IMU 的测量值 $\hat{\mathbf{a}}$ 和 $\hat{\boldsymbol{\omega}}$ 建模为

Algorithm 1: Direct LiDAR-Inertial Odometry

```

1 input:  $\hat{\mathbf{X}}_{k-1}^\mathcal{W}$ ,  $\mathcal{P}_k^\mathcal{L}$ ,  $\mathbf{a}_k^\mathcal{B}$ ,  $\boldsymbol{\omega}_k^\mathcal{B}$ ; output:  $\hat{\mathbf{X}}_k^\mathcal{W}$ ,  $\hat{\mathcal{M}}_k^\mathcal{W}$ 
2 // LiDAR Callback Thread
3 while  $\mathcal{P}_k^\mathcal{L} \neq \emptyset$  do
4   // initialize points and transform to  $\mathcal{R}$ 
5    $\tilde{\mathcal{P}}_k^\mathcal{R} \leftarrow \text{initializePointCloud}(\mathcal{P}_k^\mathcal{L})$  (Sec. III-C);
6   // continuous-time motion correction
7   for  $\hat{\mathbf{a}}_i^\mathcal{R}, \hat{\boldsymbol{\omega}}_i^\mathcal{R}$  between  $t_{k-1}$  and  $t_k$  do
8      $\hat{\mathbf{p}}_i, \hat{\mathbf{v}}_i, \hat{\mathbf{q}}_i \leftarrow$ 
9     discreteInt( $\hat{\mathbf{X}}_{k-1}^\mathcal{W}$ ,  $\hat{\mathbf{a}}_{i-1}^\mathcal{R}$ ,  $\hat{\boldsymbol{\omega}}_{i-1}^\mathcal{R}$ ) (4);
10     $\hat{\mathbf{T}}_i^\mathcal{W} = [\hat{\mathbf{R}}(\hat{\mathbf{q}}_i) | \hat{\mathbf{p}}_i]$ ;
11  end
12  for  $p_k^n \in \tilde{\mathcal{P}}_k^\mathcal{R}$  do
13     $\hat{\mathbf{T}}_n^{\mathcal{W}^*} \leftarrow \text{continuousInt}(\hat{\mathbf{T}}_i^\mathcal{W}, t_n)$  (5);
14     $\hat{p}_k^n = \hat{\mathbf{T}}_n^{\mathcal{W}^*} \otimes p_k^n$ ;  $\hat{\mathcal{P}}_k^\mathcal{W}$ .append( $\hat{p}_k^n$ );
15  end
16 // scan-to-map registration
17  $\hat{\mathcal{S}}_k^\mathcal{W} \leftarrow \text{generateSubmap}(\hat{\mathcal{M}}_k^\mathcal{W})$  [17]
18  $\hat{\mathbf{T}}_k^\mathcal{W} \leftarrow \text{GICP}(\hat{\mathcal{P}}_k^\mathcal{W}, \hat{\mathcal{S}}_k^\mathcal{W})$  (6);
19 // geometric observer: state update
20  $\hat{\mathbf{X}}_k^\mathcal{W} \leftarrow \text{update}(\hat{\mathbf{T}}_k^\mathcal{W}, \Delta t_k^+)$  (Sec. III-F);
21 // update keyframe map
22 if  $\hat{\mathcal{P}}_k^\mathcal{W}$  is a keyframe then
23    $\hat{\mathcal{M}}_k^\mathcal{W} \leftarrow \hat{\mathcal{M}}_{k-1}^\mathcal{W} \oplus \hat{\mathcal{P}}_k^\mathcal{W}$ ;
24 return  $\hat{\mathbf{X}}_k^\mathcal{W}$ ,  $\hat{\mathcal{M}}_k^\mathcal{W}$ 
25 end
26 // IMU Callback Thread
27 while  $\mathbf{a}_i^\mathcal{B} \neq \emptyset$  and  $\boldsymbol{\omega}_i^\mathcal{B} \neq \emptyset$  do
28   // apply biases and transform to  $\mathcal{R}$ 
29    $\hat{\mathbf{a}}_i^\mathcal{R}, \hat{\boldsymbol{\omega}}_i^\mathcal{R} \leftarrow \text{initializeImu}(\mathbf{a}_i^\mathcal{B}, \boldsymbol{\omega}_i^\mathcal{B})$  (Sec. III-C);
30   // geometric observer: state propagation
31    $\hat{\mathbf{X}}_i^\mathcal{W} \leftarrow \text{propagate}(\hat{\mathbf{X}}_k^\mathcal{W}, \hat{\mathbf{a}}_i^\mathcal{R}, \hat{\boldsymbol{\omega}}_i^\mathcal{R}, \Delta t_i^+)$ 
32   (Sec. III-F);
33   return  $\hat{\mathbf{X}}_i^\mathcal{W}$ 
34 end

```

$$\hat{\mathbf{a}}_i = (\mathbf{a}_i - \mathbf{g}) + \mathbf{b}_i^\mathcal{a} + \mathbf{n}_i^\mathcal{a}, \quad (2)$$

$$\hat{\boldsymbol{\omega}}_i = \boldsymbol{\omega}_i + \mathbf{b}_i^\mathcal{\omega} + \mathbf{n}_i^\mathcal{\omega}, \quad (3)$$

并用 $i = 1, \dots, M$ 对时钟时间 t_{k-1} 和 t_k 之间的 M 个测量值进行索引。为简化表述，我们略作改动，索引 k 和 i 分别表示激光雷达和惯性测量单元 (IMU) 的采样率，除非另有说明，否则将保持这种写法。原始传感器测量值 \mathbf{a}_i 和 $\boldsymbol{\omega}_i$ 包含偏差 \mathbf{b}_i 和白噪声 \mathbf{n}_i ， \mathbf{g} 是旋转后的重力向量。在本研究中，我们解决以下问题：给定激光雷达的累积点云 \mathcal{P}_k 和 IMU 在每次接收扫描之间采样的测量值 \mathbf{a}_i 和 $\boldsymbol{\omega}_i$ ，估计机器人的状态 $\hat{\mathbf{X}}_i^\mathcal{W}$ 和几何地图 $\hat{\mathcal{M}}_k^\mathcal{W}$ 。

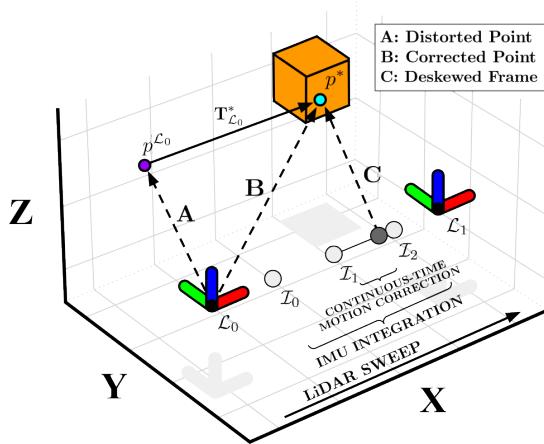


Fig. 3. 由粗到精的点云去倾斜。一个变形点 p^{L_0} (A) 通过两步过程进行去倾斜：首先在扫描之间积分 IMU 测量值，然后求解原始点在连续时间 (C) 中的唯一变换，将 p^{L_0} 去倾斜为 p^* (B)。

C. Preprocessing

DLIO 的输入是由现代 360° 机械 LiDAR (例如 Ouster 或 Velodyne (10-20Hz)) 收集的密集 3D 点云，此外还有来自 6 轴 IMU 的时间同步线性加速度和角速度测量，其频率更高 (100-500Hz)。在执行下游任务之前，所有传感器数据都通过外部校准转换为位于机器人重心的 \mathcal{R} 。对于 IMU，如果传感器与重心不重合，则必须考虑线性加速度测量对刚体产生位移的影响；这可以通过考虑 \mathcal{R} 处线性加速度的所有贡献来实现，即角速度和 IMU 偏移量的叉积。为了最大限度地减少信息丢失，我们不对点云进行预处理，除了围绕原点的大小为 1m³ 的盒式滤波器以去除可能来自机器人本身的点，以及用于更高分辨率云的光体素滤波器。这使得我们的工作有别于其他尝试检测特征（例如角、边或面元）或通过体素滤波器对云进行大量下采样的工作。

D. Continuous-Time Motion Correction with Joint Prior

由于旋转激光阵列在扫描过程中会在不同时刻采集点，旋转激光雷达传感器采集的点云在运动过程中容易发生运动畸变。我们假设扫描过程中的简单运动（即恒速运动）可能无法准确捕捉精细运动，因此我们采用更精确的恒定加速度和恒定角加速度模型，通过两步粗到精的传播方案为每个点计算独特的变换。该策略旨在最大限度地减少由于惯性测量单元 (IMU) 的采样率以及 IMU 和激光雷达点测量之间的时间偏移而产生的误差。首先通过数值 IMU 积分 [29] 粗略构建整个扫描过程的轨迹，然后通过求解 \mathcal{W} 中的一

组解析连续时间方程对其进行细化（图 3）。

令 t_k 为接收到的点云 $\mathcal{P}_k^{\mathcal{R}}$ 的时钟时间，该点云在时间段内累积了 N 个点；令 $t_k + \Delta t_k^n$ 为点云中 p_k^n 点的时间戳。为了近似计算每个点在 \mathcal{W} 中的位置，我们首先通过以下方式对 t_{k-1} 和 $t_k + \Delta t_k^N$ 之间的 IMU 测量值进行积分：

$$\begin{aligned}\hat{\mathbf{p}}_i &= \hat{\mathbf{p}}_{i-1} + \hat{\mathbf{v}}_{i-1} \Delta t_i + \frac{1}{2} \hat{\mathbf{R}}(\hat{\mathbf{q}}_{i-1}) \hat{\mathbf{a}}_{i-1} \Delta t_i^2 + \frac{1}{6} \hat{\mathbf{j}}_i \Delta t_i^3, \\ \hat{\mathbf{v}}_i &= \hat{\mathbf{v}}_{i-1} + \hat{\mathbf{R}}(\hat{\mathbf{q}}_{i-1}) \hat{\mathbf{a}}_{i-1} \Delta t_i, \\ \hat{\mathbf{q}}_i &= \hat{\mathbf{q}}_{i-1} + \frac{1}{2} (\hat{\mathbf{q}}_{i-1} \otimes \hat{\boldsymbol{\omega}}_{i-1}) \Delta t_i + \frac{1}{4} (\hat{\mathbf{q}}_{i-1} \otimes \hat{\boldsymbol{\alpha}}_i) \Delta t_i^2,\end{aligned}\quad (4)$$

其中 $i = 1, \dots, M$ 表示两次扫描之间 IMU 测量的 M 个数，其中 $\hat{\mathbf{j}}_i = \frac{1}{\Delta t_i} (\hat{\mathbf{R}}(\hat{\mathbf{q}}_i) \hat{\mathbf{a}}_i - \hat{\mathbf{R}}(\hat{\mathbf{q}}_{i-1}) \hat{\mathbf{a}}_{i-1})$ 和 $\hat{\boldsymbol{\alpha}}_i = \frac{1}{\Delta t_i} (\hat{\boldsymbol{\omega}}_i - \hat{\boldsymbol{\omega}}_{i-1})$ 是分别估计线性加速度和角加速度。对应于 $\hat{\mathbf{p}}_i$ 和 $\hat{\mathbf{q}}_i$ 的一组齐次变换 $\hat{\mathbf{T}}_i^{\mathcal{W}} \in \mathbb{SE}(3)$ 定义了扫描过程中的粗略离散时间轨迹。然后，从每个点 p_k^n 最近的前一个变换得到解析的连续时间解，恢复出特定点的去畸变变换 $\hat{\mathbf{T}}_n^{\mathcal{W}^*}$ ，使得

$$\begin{aligned}\hat{\mathbf{p}}^*(t) &= \hat{\mathbf{p}}_{i-1} + \hat{\mathbf{v}}_{i-1} t + \frac{1}{2} \hat{\mathbf{R}}(\hat{\mathbf{q}}_{i-1}) \hat{\mathbf{a}}_{i-1} t^2 + \frac{1}{6} \hat{\mathbf{j}}_i t^3, \\ \hat{\mathbf{q}}^*(t) &= \hat{\mathbf{q}}_{i-1} + \frac{1}{2} (\hat{\mathbf{q}}_{i-1} \otimes \hat{\boldsymbol{\omega}}_{i-1}) t + \frac{1}{4} (\hat{\mathbf{q}}_{i-1} \otimes \hat{\boldsymbol{\alpha}}_i) t^2,\end{aligned}\quad (5)$$

其中 $i-1$ 和 i 分别对应于最近的前一个和后一个 IMU 测量值， t 是点 p_k^n 与最近的前一个 IMU 之间的时间戳， $\hat{\mathbf{T}}_n^{\mathcal{W}^*}$ 是对应于 p_k^n 的 $\hat{\mathbf{p}}^*$ 和 $\hat{\mathbf{q}}^*$ 的变换（图 4）。注意，(5) 仅由 t 参数化，因此可以查询任意时间的变换来构建连续时间轨迹。

这两步程序的结果是一个经过运动校正的点云，它也与 \mathcal{W} 中的地图大致对齐，因此它本身就包含了用于 GICP 的优化先验 (Sec. III-E)。重要的是，(4) 和 (5) 取决于 $\hat{\mathbf{v}}_0^{\mathcal{W}}$ 的精度（初始速度估计值）、 \mathbf{b}_k^a 和 \mathbf{b}_k^{ω} （估计的 IMU 偏差），以及运动校正时准确的初始身体方向 $\hat{\mathbf{q}}_0$ （以正确补偿重力矢量）。因此，我们强调，我们方法的可靠性的关键在于，通过利用 DLIO 的非线性几何观测器 [7] 来保证这些项的全局收敛，前提是扫描匹配返回准确的解决方案。

E. Scan-to-Map Registration

通过同时校正运动畸变并将 GICP 优化先验融入点云，DLIO 可以直接执行扫描到地图的配准，并绕过先前方法中所需的扫描到扫描步骤。该配准过程被

TABLE I
COMPARISON WITH NEWER COLLEGE DATASET

Algorithm	Type	Absolute Trajectory Error (RMSE) [m]					Avg Comp. [ms]
		Short (1609.40m)	Long (3063.42m)	Quad (479.04m)	Dynamic (97.20m)	Park (695.68m)	
DLO [17]	LO	0.4633	0.4125	0.1059	0.1954	0.1846	48.10
CT-ICP [27]	LO	0.5552	0.5761	0.0981	0.1426	0.1802	412.27
LIO-SAM [4]	LIO	0.3957	0.4092	0.0950	0.0973	0.1761	179.33
FAST-LIO2 [6]	LIO	0.3775	0.3324	0.0879	0.0771	0.1483	42.86
DLIO (None)	LIO	0.4299	0.3988	0.1117	0.1959	0.1821	34.88
DLIO (Discrete)	LIO	0.3803	0.3629	0.0943	0.0798	0.1537	34.61
DLIO (Continuous)	LIO	0.3606	0.3268	0.0837	0.0612	0.1196	35.74

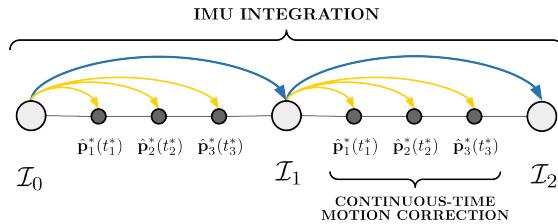


Fig. 4. 连续时间运动校正。对于云中的每个点，通过求解一组以最近的前一次 IMU 测量值初始化的闭式运动方程，计算出一个唯一的变换。这提供了精确且可并行化的连续时间运动校正。

转化为一个非线性优化问题，旨在最小化当前扫描与提取的子图之间对应点/平面的距离。令 $\hat{\mathcal{P}}_k^W$ 为 \mathcal{W} 中校正后的点云， $\hat{\mathcal{S}}_k^W$ 为通过 [17] 提取的基于关键帧的子图。然后，扫描到地图优化的目标是找到一个变换 $\Delta\hat{\mathbf{T}}_k$ ，以便更好地配准点云，使得

$$\Delta\hat{\mathbf{T}}_k = \arg \min_{\Delta\mathbf{T}_k} \mathcal{E} \left(\Delta\mathbf{T}_k \hat{\mathcal{P}}_k^W, \hat{\mathcal{S}}_k^W \right), \quad (6)$$

GICP 的残差 \mathcal{E} 定义为

$$\mathcal{E} \left(\Delta\mathbf{T}_k \hat{\mathcal{P}}_k^W, \hat{\mathcal{S}}_k^W \right) = \sum_{c \in \mathcal{C}} d_c^\top \left(C_{k,c}^S + \Delta\mathbf{T}_k C_{k,c}^P \Delta\mathbf{T}_k^\top \right)^{-1} d_c,$$

在时间步 k 处， $\hat{\mathcal{P}}_k^W$ 和 $\hat{\mathcal{S}}_k^W$ 之间的一组 C 个对应点， $d_c = \hat{s}_k^c - \Delta\mathbf{T}_k \hat{p}_k^c$ ， $\hat{p}_k^c \in \hat{\mathcal{P}}_k^W$ ， $\hat{s}_k^c \in \hat{\mathcal{S}}_k^W$ ， $\forall c \in \mathcal{C}$ ，以及 $C_{k,c}^P$ 和 $C_{k,c}^S$ 分别是点云 $\hat{\mathcal{P}}_k^W$ 和子图 $\hat{\mathcal{S}}_k^W$ 的估计协方差矩阵。然后，按照 [10] 的方法，通过用 $(1, 1, \epsilon)$ 个特征值对协方差矩阵 $C_{k,c}^P$ 和 $C_{k,c}^S$ 进行正则化，将点到平面公式转化为平面到平面优化公式，其中 ϵ 表示表面法线方向的低不确定性。得到的 $\Delta\hat{\mathbf{T}}_k$ 表示最佳校正变换，该变换可以更好地全局对齐先前变换的扫描 $\hat{\mathcal{P}}_k^W$ 和子地图 $\hat{\mathcal{S}}_k^W$ ，从而 $\hat{\mathbf{T}}_k^W = \Delta\hat{\mathbf{T}}_k \hat{\mathbf{T}}_M^W$ （其中 $\hat{\mathbf{T}}_M^W$ 是最后一点的 IMU 积分）是全局优化的机器人位姿，用于地图构建并作为非线性几何观测器的更新信号。

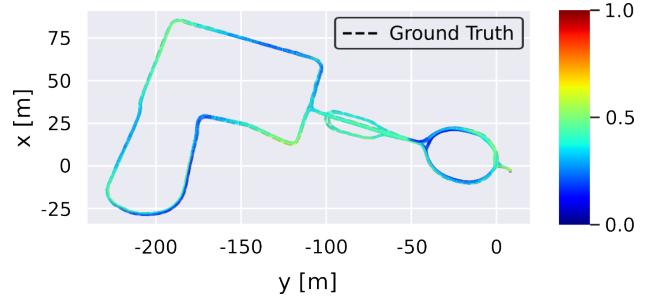


Fig. 5. 长距离实验轨迹。DLIO 为“the Newer College - 长距离实验”生成的轨迹。颜色表示绝对位姿误差。

F. Geometric Observer

将通过扫描到地图对齐计算出的变换 $\hat{\mathbf{T}}_k^W$ 与 IMU 测量值融合，通过一种新颖的分层非线性几何观测器生成完整的状态估计 $\hat{\mathbf{X}}_k$ 。该观测器的完整分析可在 [7] 中找到，但总而言之，可以证明 $\hat{\mathbf{X}}$ 在确定性设置下将以最少的计算量全局收敛到 \mathbf{X} 。该证明利用收缩理论，首先证明四元数估计值呈指数级收敛到真实四元数附近的区域。然后，方向估计值作为另一个收缩观测器的输入，用于估计平移状态。该架构形成了一个收缩层次结构，确保估计值收敛到其真实值。这种强大的收敛结果是其优于其他融合方案（例如滤波或位姿图优化）的主要优势，因为这些方案即使在最理想的设置下也难以保证收敛。此外，观测器状态估计的固有平滑性使其非常适合控制。本文中使用的观测器是 [7] 中观测器的一个特例。

令 $\gamma_{\ell \in \{1, \dots, 5\}}$ 为正常数， Δt_k^+ 为 GICP 姿势之间的时间。如果 $\mathbf{q}_e := (q_e^\circ, \vec{q}_e) = \hat{\mathbf{q}}_i^* \otimes \hat{\mathbf{q}}_k$ 且 $\mathbf{p}_e = \hat{\mathbf{p}}_k - \hat{\mathbf{p}}_i$ （传播位姿与测量位姿之间的误差），则状态校正的形

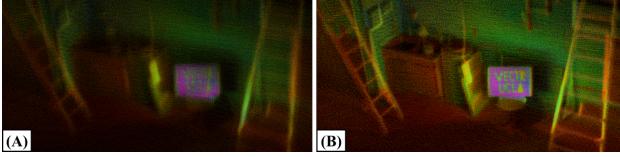


Fig. 6. 去倾斜比较。未使用 (A) 和使用 (B) 我们的运动校正方法的激进操作生成的地图。

式为

$$\begin{aligned}\hat{\mathbf{q}}_i &\leftarrow \hat{\mathbf{q}}_i + \Delta t_k^+ \gamma_1 \hat{\mathbf{q}}_i \otimes \begin{bmatrix} 1 - |q_e^\circ| \\ \text{sgn}(q_e^\circ) \vec{q}_e \end{bmatrix}, \\ \hat{\mathbf{b}}_i^\omega &\leftarrow \hat{\mathbf{b}}_i^\omega - \Delta t_k^+ \gamma_2 q_e^\circ \vec{q}_e, \\ \hat{\mathbf{p}}_i &\leftarrow \hat{\mathbf{p}}_i + \Delta t_k^+ \gamma_3 \mathbf{p}_e, \\ \hat{\mathbf{v}}_i &\leftarrow \hat{\mathbf{v}}_i + \Delta t_k^+ \gamma_4 \mathbf{p}_e, \\ \hat{\mathbf{b}}_i^a &\leftarrow \hat{\mathbf{b}}_i^a - \Delta t_k^+ \gamma_5 \hat{\mathbf{R}}(\hat{\mathbf{q}}_i)^\top \mathbf{p}_e.\end{aligned}\quad (7)$$

注意：(7) 与姿态更新（前两个方程）一样，是分层的。与平移更新（最后三个方程）完全解耦。此外，(7) 是一个完全非线性的更新，它能够保证状态估计足够准确，从而仅使用 IMU 先验知识即可直接执行扫描到地图的配准，而无需进行扫描到扫描。

IV. RESULTS

使用 Newer College 基准数据集 [30] 和加州大学洛杉矶分校 (UCLA) 校园内自行收集的数据对 DLIO 进行了评估。我们将准确度和效率与四种当前最佳算法进行比较，这四种算法分别是 DLO [17]、CT-ICP [27]、LIO-SAM [4] 和 FAST-LIO2 [6]。每种算法采用不同程度和方法的运动补偿，因此可以与当前最佳算法进行详尽的比较。除外部参数外，除非另有说明，所有实验均使用每种算法在撰写本文时的默认参数。具体而言，LIO-SAM 启用了回环闭包，而 FAST-LIO2 禁用了在线外部参数估计，以提供每种算法的最佳结果。对于 CT-ICP，我们略微增加了体素化程度，并降低了数据回放速度，否则算法会因严重丢帧而失败。所有测试均在 16 核 Intel i7-11800H CPU 上进行。

A. Ablation Study and Comparison of Motion Correction

为了探究我们提出的运动校正方案的影响，我们首先使用 Newer College 数据集 [30] 对 DLIO 进行了不同程度的去畸变消融研究。本研究的范围从无运动校正 (None) 到仅使用 (4) (离散) 进行最近 IMU 积分校正，最后到通过 (4) 和 (5) (连续) 进行完全连

续时间运动校正（表格 I）。特别值得注意的是动态数据集，其中包含高度剧烈的运动，旋转速度高达 3.5 rad/s。在没有校正的情况下，误差是所有算法中最高的，为 0.1959 RMSE。经过部分校正后，由于扫描匹配了更准确、更具代表性的点云，误差显著降低；然而，使用完整的方案，我们观察到的 RMSE 误差仅为 0.0612，在所有测试算法中最低。其他所有数据集的趋势都类似，更佳的运动校正带来的卓越追踪精度显而易见：构建独特的连续时间变换比以往方法能够创建更真实的点云，这最终会影响扫描匹配，从而影响轨迹精度。图 6 以实证方式展示了这一点：DLIO 可以捕捉到微小的细节，而这些细节在简单的运动校正或无运动校正的情况下会丢失。

B. Benchmark Results

1) *Newer College Dataset*: 我们还使用原始 Newer College 基准数据集 [30] 通过 evo [31] 比较了所有算法的轨迹精度和平均每次扫描时间。在这些测试中，我们使用了 Ouster 的 IMU 数据 (100Hz) 以及 LiDAR 数据 (10Hz)，以确保传感器之间的精确时间同步。对于某些 Newer College 数据集，为了提供公平的比较，由于初始阶段存在滑移，前 100 个姿态被排除在 FAST-LIO2 的 RMSE 计算之外。我们还使用 Newer College 数据集的最新扩展 [32] 进行了比较，并观察到了类似的结果，但由于篇幅限制，这些结果被省略了。结果显示在表 I 中，其中我们观察到与最先进的技术相比，DLIO 产生了最低的轨迹 RMSE 和最低的每次扫描总体计算时间（对所有五个数据集取平均值）。Fig. 5 表明，即使行驶了超过三公里，DLIO 的轨迹误差与 Newer College - Long Experiment 数据集的地面真实情况相比仍然很低。

2) *UCLA Campus Dataset*: 此外，我们在加州大学洛杉矶分校 (UCLA) 收集了四个大规模数据集，用于进一步比较（图 7）。这些数据集是通过手持空中平台（图 1）在 2261.37 米的总轨迹上采集的。我们的传感器套件包括一个 Ouster OS1 (10Hz, 32 通道，水平分辨率为 512) 和一个位于其下方约 0.1 米的 6 轴 InvenSense MPU-6050 IMU。我们在此指出，这款 IMU 的售价约为 10 美元，这表明 LIO 算法不需要像以前的研究那样使用高端 IMU 传感器。需要注意的是，由于缺乏地面实况数据，无法比较绝对轨迹误差，因此按照惯例，我们计算端到端平移误差作为替代指

TABLE II
COMPARISON WITH UCLA CAMPUS DATASET

Algorithm	Type	End-to-End Translational Error [m]				Avg. Comp. [ms]			
		A (652.66m)	B (526.58m)	C (551.38m)	D (530.75m)	A	B	C	D
DLO [17]	LO	0.0216	1.2932	0.0375	0.0178	20.40	20.77	21.18	21.62
CT-ICP [27]	LO	0.0387	0.0699	0.0966	0.0253	351.85	342.76	334.15	370.19
LIO-SAM [4]	LIO	0.0216	0.0692	0.0936	0.0249	33.21	29.14	39.04	48.94
FAST-LIO2 [6]	LIO	0.0454	0.0353	0.0363	0.0229	15.39	12.25	14.84	15.01
DLIO	LIO	0.0105	0.0233	0.0301	0.0082	10.45	8.37	8.66	10.96

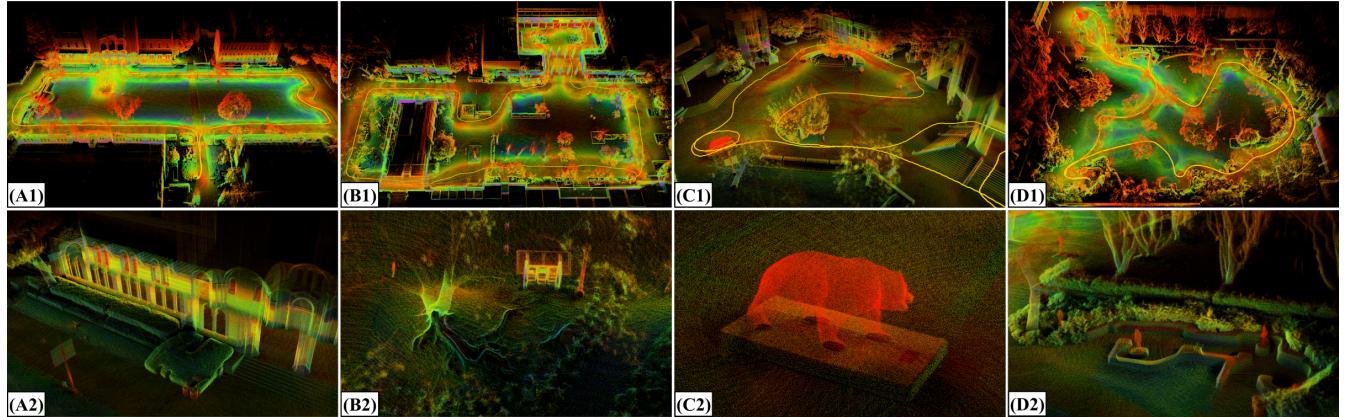


Fig. 7. 加州大学洛杉矶分校校园。DLIO 生成的加州大学洛杉矶分校周边地点的详细地图，包括 (A) 迪克森庭院的罗伊斯大厅 (Royce Hall)、(B) 科学院、(C) 布鲁因广场 (Bruin Plaza) 和 (D) 富兰克林 · D · 墨菲雕塑花园。地图上分别包含 (1) 鸟瞰图和 (2) 特写图，以展示 DLIO 生成的精细程度。生成这些地图的轨迹在第一行以黄色显示。

标(表格 II)。在这些实验中，DLIO 在端到端平移误差和单次扫描效率方面均全面超越其他所有系统。DLIO 生成的地图能够捕捉环境中的精细细节，最终为自主移动机器人提供更复杂的信息线索，例如地形可穿越性。

V. CONCLUSION

本研究提出了直接激光雷达惯性里程计 (DLIO)，这是一种高度可靠的 LIO 算法，可为资源受限的移动机器人实时生成精确的状态估计和详细地图。DLIO 区别于其他算法的关键创新在于其快速且可并行化的由粗到精的连续时间轨迹构建方法，用于逐点运动校正。该方法内置于一个简化的 LIO 架构中，该架构一次性完成运动校正和先验构建，此外还直接执行扫描到地图的对齐，以降低计算开销。这一切的实现得益于我们观测器强大的收敛保证，它能够可靠地初始化位姿、速度和偏差，从而实现精确的 IMU 集成。我们的实验结果表明，与最先进的技术相比，DLIO 的定位精度、地图清晰度和算法效率均有所提升，未来的工作包括闭环飞行测试和添加回环功能。

致谢：作者感谢 Helene Levy 和 David Thorne 在数据收集方面提供的帮助。

REFERENCES

- [1] C. Cadena, L. Carlone, H. Carrillo, Y. Latif, D. Scaramuzza, J. Neira, I. Reid, and J. J. Leonard, “Past, present, and future of simultaneous localization and mapping: Toward the robust-perception age,” *IEEE Transactions on Robotics*, vol. 32, no. 6, pp. 1309–1332, 2016.
- [2] J. Zhang and S. Singh, “Loam: Lidar odometry and mapping in real-time.” in *Robotics: Science and Systems*, vol. 2, no. 9, 2014, pp. 1–9.
- [3] T. Shan and B. Englot, “Lego-loam: Lightweight and ground-optimized lidar odometry and mapping on variable terrain,” in *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2018, pp. 4758–4765.
- [4] T. Shan, B. Englot, D. Meyers, W. Wang, C. Ratti, and D. Rus, “Lio-sam: Tightly-coupled lidar inertial odometry via smoothing and mapping,” in *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2020, pp. 5135–5142.
- [5] W. Xu and F. Zhang, “Fast-lio: A fast, robust lidar-inertial odometry package by tightly-coupled iterated kalman filter,” *IEEE Robotics and Automation Letters*, vol. 6, no. 2, pp. 3317–3324, 2021.
- [6] W. Xu, Y. Cai, D. He, J. Lin, and F. Zhang, “Fast-lio2: Fast direct lidar-inertial odometry,” *IEEE Transactions on Robotics*, 2022.
- [7] B. T. Lopez, “A contracting hierarchical observer for pose-inertial fusion,” *arXiv:2303.02777*, 2023.
- [8] P. J. Besl and N. D. McKay, “Method for registration of 3-d shapes,” in *Sensor fusion IV: control paradigms and data structures*, vol. 1611, 1992, pp. 586–606.
- [9] Y. Chen and G. Medioni, “Object modelling by registration of multiple range images,” *Image and vision computing*, vol. 10, no. 3, pp. 145–155, 1992.

- [10] A. Segal, D. Haehnel, and S. Thrun, “Generalized-icp,” in *Robotics: science and systems*, vol. 2, no. 4, 2009, p. 435.
- [11] T. Shan, B. Englot, C. Ratti, and D. Rus, “Lvi-sam: Tightly-coupled lidar-visual-inertial odometry via smoothing and mapping,” in *2021 IEEE International Conference on Robotics and Automation (ICRA)*, 2021, pp. 5692–5698.
- [12] Y. Pan, P. Xiao, Y. He, Z. Shao, and Z. Li, “Mulls: Versatile lidar slam via multi-metric linear least square,” in *2021 IEEE International Conference on Robotics and Automation (ICRA)*, 2021, pp. 11633–11640.
- [13] T.-M. Nguyen, S. Yuan, M. Cao, L. Yang, T. H. Nguyen, and L. Xie, “Miliom: Tightly coupled multi-input lidar-inertia odometry and mapping,” *IEEE Robotics and Automation Letters*, vol. 6, no. 3, pp. 5573–5580, 2021.
- [14] H. Ye, Y. Chen, and M. Liu, “Tightly coupled 3d lidar inertial odometry and mapping,” in *International Conference on Robotics and Automation*, 2019, pp. 3144–3150.
- [15] M. Palieri, B. Morrell, A. Thakur, K. Ebadi, J. Nash, A. Chatterjee, C. Kanellakis, L. Carlone, C. Guaragnella, and A.-a. Agha-Mohammadi, “Locus: A multi-sensor lidar-centric solution for high-precision odometry and 3d mapping in real-time,” *IEEE Robotics and Automation Letters*, vol. 6, no. 2, 2020.
- [16] A. Tagliabue, J. Tordesillas, X. Cai, A. Santamaría-Navarro, J. P. How, L. Carlone, and A.-a. Agha-mohammadi, “Lion: Lidar-inertial observability-aware navigator for vision-denied environments,” in *International Symposium on Experimental Robotics*, 2020, pp. 380–390.
- [17] K. Chen, B. T. Lopez, A.-a. Agha-mohammadi, and A. Mehta, “Direct lidar odometry: Fast localization with dense point clouds,” *IEEE Robotics and Automation Letters*, vol. 7, no. 2, pp. 2000–2007, 2022.
- [18] A. Reinke, M. Palieri, B. Morrell, Y. Chang, K. Ebadi, L. Carlone, and A.-A. Agha-Mohammadi, “Locus 2.0: Robust and computationally efficient lidar odometry for real-time 3d mapping,” *IEEE Robotics and Automation Letters*, pp. 1–8, 2022.
- [19] J. Zhang, M. Kaess, and S. Singh, “On degeneracy of optimization-based state estimation problems,” in *2016 IEEE International Conference on Robotics and Automation (ICRA)*, 2016, pp. 809–816.
- [20] G. Baldwin, R. Mahony, J. Trumpf, T. Hamel, and T. Cheviron, “Complementary filter design on the special euclidean group $se(3)$,” in *2007 European Control Conference (ECC)*. IEEE, 2007.
- [21] J. F. Vasconcelos, C. Silvestre, and P. Oliveira, “A nonlinear gps/imu based observer for rigid body attitude and position estimation,” in *2008 47th IEEE Conference on Decision and Control*. IEEE, 2008, pp. 1255–1260.
- [22] T. Renzler, M. Stoltz, M. Schratter, and D. Watzenig, “Increased accuracy for fast moving lidars: Correction of distorted point clouds,” in *IEEE International Instrumentation and Measurement Technology Conference*, 2020.
- [23] S.-P. Deschênes, D. Baril, V. Kubelka, P. Giguere, and F. Pomerleau, “Lidar scan registration robust to extreme motions,” in *Conference on Robots and Vision*, 2021.
- [24] C. Park, P. Moghadam, S. Kim, A. Elfes, C. Fookes, and S. Sridharan, “Elastic lidar fusion: Dense map-centric continuous-time slam,” in *2018 IEEE International Conference on Robotics and Automation (ICRA)*, 2018, pp. 1206–1213.
- [25] M. Ramezani, K. Khosoussi, G. Catt, P. Moghadam, J. Williams, P. Borges, F. Pauling, and N. Kottege, “Wildcat: Online continuous-time 3d lidar-inertial slam,” *arXiv:2205.12595*, 2022.
- [26] D. Droseschel and S. Behnke, “Efficient continuous-time slam for 3d lidar-based online mapping,” in *2018 IEEE International Conference on Robotics and Automation (ICRA)*, 2018, pp. 5000–5007.
- [27] P. Dellenbach, J.-E. Deschaud, B. Jacquet, and F. Goulette, “Ct-icp: Real-time elastic lidar odometry with loop closure,” in *2022 International Conference on Robotics and Automation (ICRA)*. IEEE, 2022, pp. 5580–5586.
- [28] C. Park, P. Moghadam, J. L. Williams, S. Kim, S. Sridharan, and C. Fookes, “Elasticity meets continuous-time: Map-centric dense 3d lidar slam,” *IEEE Transactions on Robotics*, vol. 38, no. 2, pp. 978–997, 2022.
- [29] C. Forster, L. Carlone, F. Dellaert, and D. Scaramuzza, “On-manifold preintegration for real-time visual–inertial odometry,” *IEEE Transactions on Robotics*, vol. 33, no. 1, pp. 1–21, 2016.
- [30] M. Ramezani, Y. Wang, M. Camurri, D. Wisth, M. Mattamala, and M. Fallon, “The newer college dataset: Handheld lidar, inertial and vision with ground truth,” in *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2020, pp. 4353–4360.
- [31] M. Grupp, “evo: Python package for the evaluation of odometry and slam.” <https://github.com/MichaelGrupp/evo>, 2017.
- [32] L. Zhang, M. Camurri, and M. Fallon, “Multi-camera lidar inertial extension to the newer college dataset,” *arXiv:2112.08854*, 2021.